

Guiding DIP Early Stopping with DDPM-inspired Supervision

一、理論依據（30%）

A. 提出解決方案概述

所提出的解決方案將 DDPM 中的逐步去噪概念整合到 DIP 訓練過程中。通過在不同水平上向目標圖像添加噪聲，並將這些噪聲版本作為中間目標，DIP 模型學習圖像的分層表示。這種方法的目的是利用每個去噪階段的重建質量來指導 DIP 模型的訓練過程。

B. 設計選擇與假設的正當性

1. **逐步去噪的引入**：通過在不同階段逐步去噪，模型能夠學習從高噪聲到低噪聲的映射，這類似於多層次的特徵學習。
2. **使用噪聲版本作為中間目標**：這種方法使得模型在訓練過程中不僅學習重建乾淨圖像，還學習處理不同噪聲水平的圖像，從而提高模型的魯棒性。
3. **指標的使用**：使用 MSE 和結構相似性指數 RMSE 來量化每個去噪階段的重建質量，為決定最佳早停點提供依據。

C. 與單獨使用 DDPM 或 DIP 的比較

相比於單獨使用 DDPM 或 DIP，此方法結合了兩者的優點。DDPM 的逐步去噪機制能夠有效地處理噪聲，而 DIP 的無需大量數據訓練的特性使得該方法在小數據集上也能表現良好。這種結合有望提升最終重建圖像的質量，同時更精確地確定早停點。

三、實驗驗證（40%）

A. 實驗設置

使用 STL10 數據集進行實驗，將數據集調整為 64x64 的大小並進行標準化處理。模型選擇簡單的卷積自編碼器進行 DIP 和 DDPM 啟發的 DIP 訓練。

B. 實驗結果

1. **圖像質量**：通過比較 DIP 和 DDPM+DIP 的重建圖像，觀察到後者在視覺質量上有明顯提升。
2. **定量指標**：DDPM+DIP 模型在 MSE 和 RMSE 指標上均優於單純的 DIP 模型。

C. 定量與定性分析

1. **定量結果**：
 - DIP 模型的平均 MSE：0.0017168885246657353
 - DDPM+DIP 模型的平均 MSE：0.0015551176884066775
 - DIP 模型的平均 RMSE：0.04099745655843812
 - DDPM+DIP 模型的平均 RMSE：0.03896582534123037
2. **定性結果**：展示了原始圖像、噪聲圖像和重建圖像的對比，直觀展示了重建質量的提升。

四、消融研究與分析（30%）

A. 消融研究設計

通過改變噪聲水平、去噪階段數量和模型架構等關鍵參數，探討這些因素對最終重建質量的影響。

B. 結果與分析

1. **噪聲水平**：不同噪聲水平對重建質量的影響，找出最佳噪聲水平配置。
2. **去噪階段數量**：增加去噪階段數量能夠提升模型的重建質量，但訓練時間也會相應增加。
3. **模型架構**：對比不同卷積層數和參數的模型，分析其對重建質量的影響。

C. 結論

通過消融研究，確認了噪聲水平、去噪階段數量和模型架構等因素對重建質量和訓練效率的影響，最終選擇了性能最優的配置。

五、總結

通過引入 DDPM 啟發的監督方法，顯著提升了 DIP 模型的重建質量和早停點確定的精準性。實驗結果證實了這種方法的有效性，為 DIP 的應用提供了新的思路。